Resolución Actividad 2 Máster Bioinformática UNIR (2025)

Melissa Ndombasi Bokuy

2025-12-14

Introducción

En este proyecto se trabajará con un dataset que contiene información de la expresión de 40 genes en 65 pacientes, cada uno con distintos tipos de tratamiento y características tumorales. El objetivo es calcular los descriptivos de las diferentes variables, comprobar la normalidad de la distribución de la expresión de los genes, valorar las diferencias en la expresión génica en función de diferentes variables y resumir la información de interés en tablas resumen para la presentación de resultados.

Presentación de resultados

En las tabla descriptivas, se reflejarán las medias y desviaciones estándar en caso de ser datos paramétricos; y las medianas y rangos intercuartílicos si son datos no paramétricos. Así como el valor P del contraste de hipótesis correspondiente a cada una de las variables para determinar si existen diferencias significativas entre los pacientes sometidos o no a tratamiento y así como en función de su extensión tumoral.

1. Instalar y cargar librerías

Comenzamos instalando y cargando los paquetes necesarios para el uso de las librerías de interés para el análisis. Sólo se requiere la instalación si no han sido previamente instalados.

```
# install.packages(c("ggplot2", "dplyr", "tidyr", "readr", "scales", "patchwork

library(ggplot2) # Gráficos principales
library(dplyr) # Manipulación de datos
library(tidyr) # Transformación de datos
library(readr) # Importar datos
library(scales) # Funciones extra para escalas
library(patchwork) # Combinar gráficos fácilmente
library(pheatmap) # Heatmaps
library(gtsummary) # tablas descriptivas
```

```r
library(nortest) # prueba de normalidad
library(gt) # Formatear tablas a formato gt
```

2. Importar datos

Establecemos el directorio de trabajo, importamos el archivo de datos y realizamos una primera observación del fichero para entender su contenido y estructura.

```r
getwd
setwd("~/Documents/Máster bioinformática 2025-2027/Estadistica y R para Ciencia
datos <- read.csv("Actividades/Actividad 2/mubio02_act2(1)/MUBioinfo_dataset_ge
View(datos)
str(datos)
summary(datos)
```

3. Exploración de los datos

En primer lugar, elaboramos una tabla descriptiva de las variables del dataset para tener una idea preliminar de su comportamiento. Para ello, extraemos los descriptivos básicos en función del tipo de variable:

- Categóricas: indicamos un recuento de los valores presentes en cada categoría.
- Numéricas: se utiliza el test de Anderson-Darling (dada N > 50) para diferenciar entre variables paramétricas y no paramétricas.
  - Paramétricas: mostrarán media y desviación típica.
  - No paramétricas: devolverán el valor de la mediana y los cuartiles 0.25 y 0.75.

```r
descriptivo_var <- function(x) {
  x_no_na <- x[!is.na(x)]

  # Variables categóricas
  if (is.factor(x) || is.character(x)) {
    tab <- table(x_no_na)
    return(paste(names(tab), tab, sep = ": ", collapse = "; "))
  }

  # Variables  continuas
  if (is.numeric(x)) {
    p_norm <- ad.test(x_no_na)$p.value

    if (p_norm >= 0.05) {
      return(paste0(
        "media = ", round(mean(x_no_na), 2),
        ", var = ", round(var(x_no_na), 2)
      ))
```

```r
    } else {
      return(paste0(
        "mediana = ", round(median(x_no_na), 2),
        " (", round(quantile(x_no_na, 0.25), 2),
        "-", round(quantile(x_no_na, 0.75), 2), ")"
      ))
    }
  }

  return(NA)
}

# Aplicación de la función al dataset

tabla_descriptivos <- data.frame(
  Variable = names(datos),
  Resumen = sapply(datos, descriptivo_var),
  row.names = NULL
)

tabla_descriptivos # Visualización de los resultados en la consola R
```

```r
# Formatear tabla con formato gt

tabla_gt <- tabla_descriptivos %>%
  gt() %>%
  tab_header(
    title = "Tabla descriptiva de las variables",
    subtitle = "Variables categóricas y cuantitativas"
  ) %>%
  cols_label(
    Variable = "Variable",
    Resumen  = "Descriptivo"
  ) %>%
  tab_options(
    table.font.size = px(13),
    heading.title.font.size = px(15),
    heading.subtitle.font.size = px(12)
  ) %>%
  opt_all_caps() %>%
  opt_table_outline()

tabla_gt
```

Tabla descriptiva de las variables

Variables categóricas y cuantitativas

VARIABLE	DESCRIPTIVO
id	media = 33, var = 357.5
tratamiento	farmaco: 32; placebo: 33
extension	localizado: 32; metastasico: 33
edad	media = 65.46, var = 140.29
sexo	mujer: 40; varon: 25
exfumador	no: 34; si: 31
hta	no: 39; si: 26
dm	no: 53; si: 12
alergia	no: 58; si: 7
cardiopatia	no: 56; si: 9
ete	no: 58; si: 7
neumopatia	no: 51; si: 14
hepatopatia	no: 62; si: 3
colelitiasis	no: 59; si: 6
utolitiasis	no: 63; si: 2
itu	no: 63; si: 2
renal	no: 63; si: 2
neuropatia	no: 53; si: 12
corticoides	antiemesis: 27; no: 30; si: 8
tos	no: 57; si: 8
disnea	no: 57; si: 8
expect	no: 55; si: 10
secrecion	no: 50; si: 15
dolor_garg	no: 62; si: 3
escalofrios	no: 61; si: 4
fiebre	no: 64; si: 1
diarrea	no: 55; si: 10
nauseas	no: 57; si: 8
vomitos	no: 62; si: 3
cefalea	no: 50; si: 15
mareo	no: 57; si: 8

cansancio	no: 35; si: 30
anosmia	no: 64; si: 1
disgueusia	no: 59; si: 6
dolor_hueso	no: 38; si: 27
dolor_abdo	no: 52; si: 13
perd_ape	no: 51; si: 14
glucosa	mediana = 105 (91-114)
leucocitos	mediana = 5.69 (4.39-7.52)
linfocitos	media = 1.47, var = 0.38
neutrofilos	mediana = 3.65 (2.35-5.2)
score_dieta	mediana = 9 (7-10)
chol	media = 176.82, var = 1249.68
hdl	media = 49.17, var = 240.04
hierro	mediana = 67 (53-84)
iga	mediana = 190.83 (153-255.13)
ige	mediana = 59.59 (13-94.6)
igg	mediana = 854.86 (711.93-938.87)
ign	mediana = 79 (62-96)
ldl	mediana = 195 (170.87-220)
pcr	mediana = 4.8 (1.1-11)
transferrina	media = 255.6, var = 1996.4
trigliceridos	mediana = 129 (90-173)
cpk	mediana = 57 (37-91)
calidad_fisica	media = 38.99, var = 121.26
calidad_mental	mediana = 50.89 (46.57-56.82)
AQ_actb	mediana = 0.39 (0.05-0.49)
AQ_gapdh	mediana = 0.37 (0.05-0.51)
AQ_b2m	mediana = 0.38 (0.05-0.5)
AQ_rpl13a	mediana = 0.39 (0.05-0.51)
AQ_hprt1	mediana = 0.41 (0.05-0.49)
AQ_vegfa	mediana = 0.41 (0.05-0.51)
AQ_il6	mediana = 0.4 (0.05-0.51)

AQ_tnf	mediana = 0.38 (0.05-0.49)
AQ_egfr	mediana = 0.4 (0.05-0.48)
AQ_cxcl8	mediana = 0.36 (0.05-0.49)
AQ_esr1	mediana = 0.65 (0.05-0.9)
AQ_her2	mediana = 0.63 (0.04-0.91)
AQ_brca1	mediana = 0.69 (0.05-0.93)
AQ_brca2	mediana = 0.7 (0.05-0.94)
AQ_mki67	mediana = 0.69 (0.05-0.87)
AQ_gata3	mediana = 0.7 (0.05-0.94)
AQ_foxa1	mediana = 0.63 (0.05-0.9)
AQ_ccnd1	mediana = 0.63 (0.04-0.88)
AQ_cdh1	mediana = 0.64 (0.05-0.93)
AQ_tp53	mediana = 0.68 (0.05-0.91)
AQ_mmp9	mediana = 0.05 (0.04-0.22)
AQ_pten	mediana = 0.05 (0.04-0.21)
AQ_myc	mediana = 0.05 (0.04-0.22)
AQ_kras	mediana = 0.05 (0.04-0.21)
AQ_akt1	mediana = 0.05 (0.05-0.22)
AQ_cdkn2a	mediana = 0.06 (0.05-0.2)
AQ_pdcd1	mediana = 0.05 (0.04-0.23)
AQ_ctla4	mediana = 0.06 (0.05-0.21)
AQ_hlaa	mediana = 0.05 (0.05-0.18)
AQ_casp3	mediana = 0.05 (0.04-0.21)

PARTE 1 - Comprobar la normalidad de los genes y realizar una interpretación de los resultados obtenidos.

A/ Histogramas de la expresión de los genes, para obtener una primera idea de su distribución.

```
df_AQ <- datos %>% select(contains("AQ"))
head(df_AQ)

AQ_names <- names(df_AQ) # nombre variables
histograms <- list() # lista vacía
```

```r
for (i in AQ_names) {
  h <- ggplot(df_AQ, aes_string(i)) +
    geom_histogram(
      bins = 30, # número de barras
      color = "white", # color del borde de las barras
      fill = "skyblue", alpha = 0.8 # color de relleno de las barras
    ) +
    labs(
      title = i,
      x = paste0("Valores de", i),
      y = "Frecuencia"
    ) +
    theme_minimal()

  # Guardar en la lista con nombre h_[var]
  histograms[[paste0("h_", i)]] <- h
}
```

```r
# Gráfico combinado de los histogramas variables de 1-12
combined_histograms_1 <- (histograms[[1]] + histograms[[2]] + histograms[[3]] +
  plot_layout(ncol = 4, nrow = 4) +
  plot_annotation(
    title = "Histogramas de los valores de expresion de cada gen",
    theme = theme_minimal()
  )

# Gráfico combinado de los histogramas variables de 13-25
combined_histograms_2 <- (histograms[[13]] + histograms[[14]] + histograms[[15]
  plot_layout(ncol = 4, nrow = 4) +
  plot_annotation(
    title = "Histogramas de los valores de expresion de cada gen",
    theme = theme_minimal()
  )

# Gráfico combinado de los histogramas variables de 26-30
combined_histograms_3 <- (histograms[[26]] + histograms[[27]] + histograms[[28]
  plot_layout(ncol = 4, nrow = 4) +
  plot_annotation(
    title = "Histogramas de los valores de expresion de cada gen",
    theme = theme_minimal()
  )
combined_histograms_1;combined_histograms_2;combined_histograms_3
```

Histogramas de los valores de expresion de cada gen

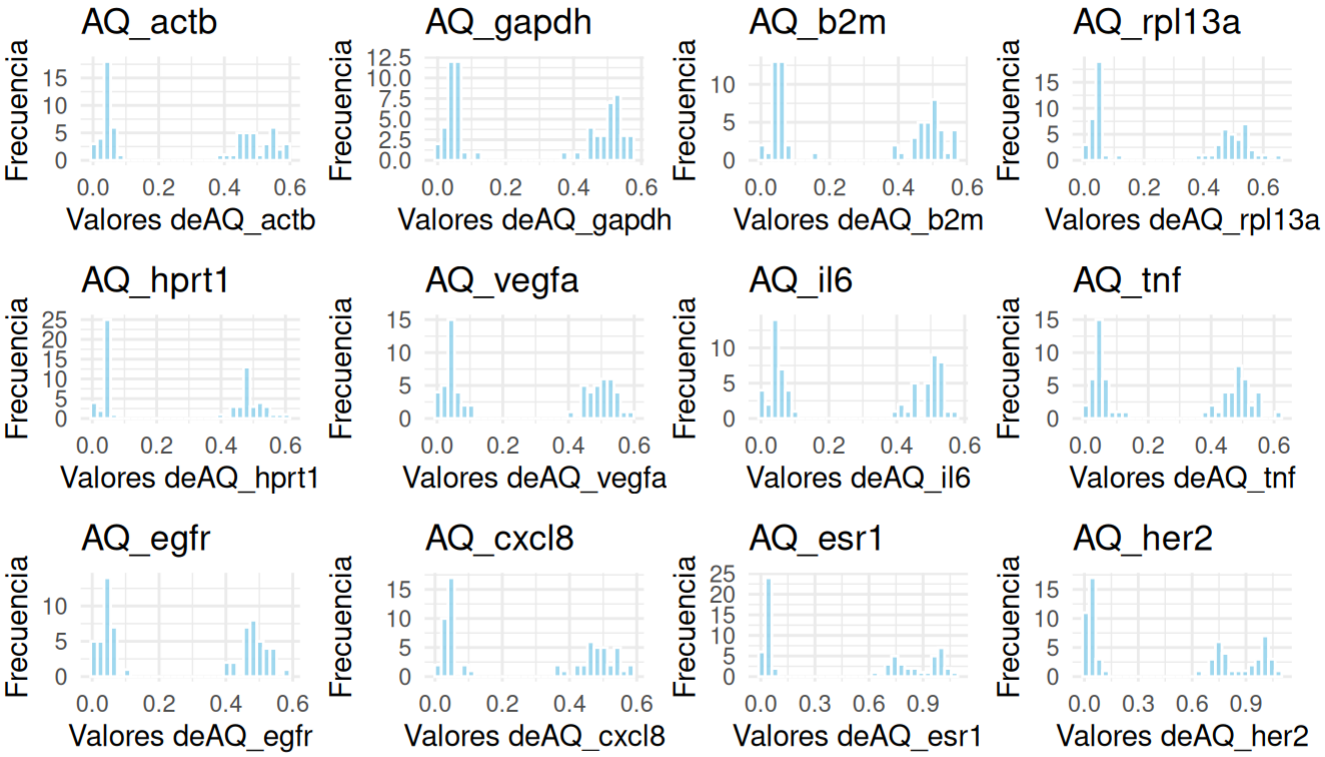

Histogramas de los valores de expresion de cada gen

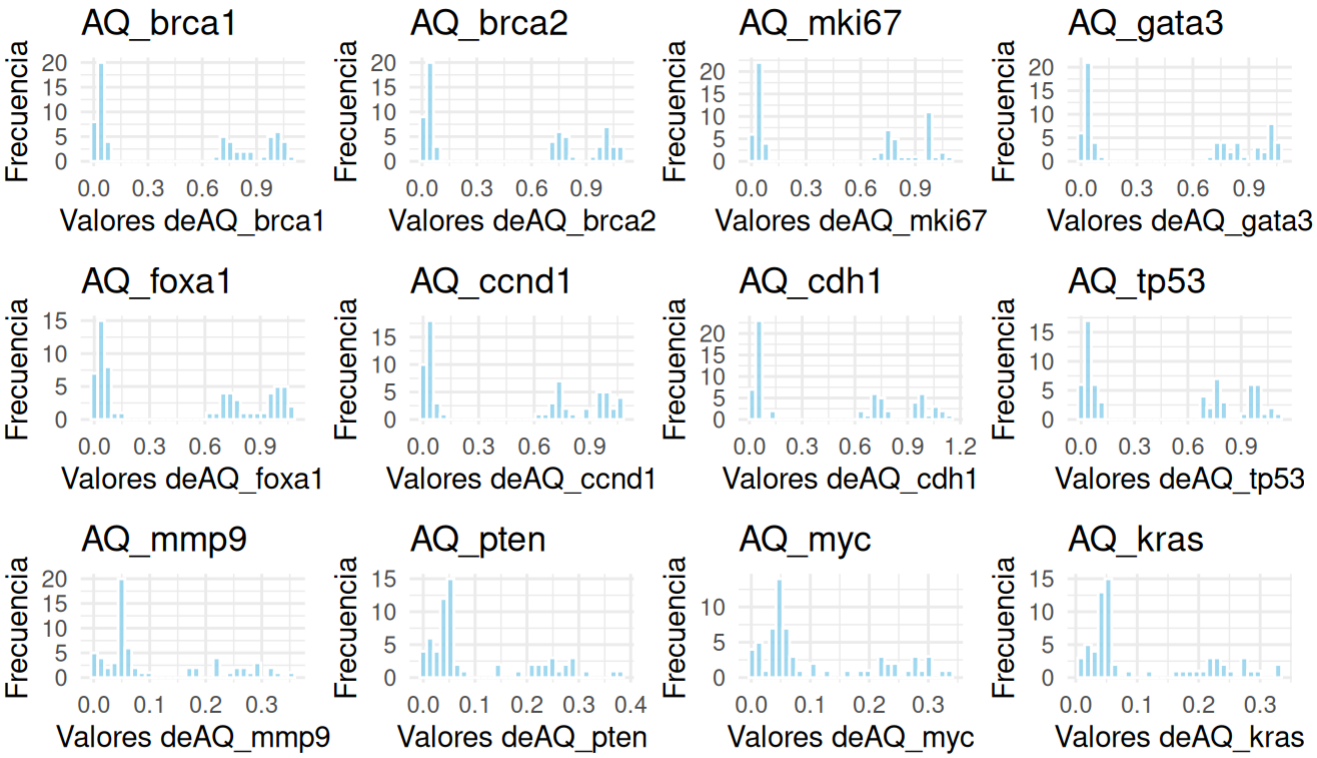

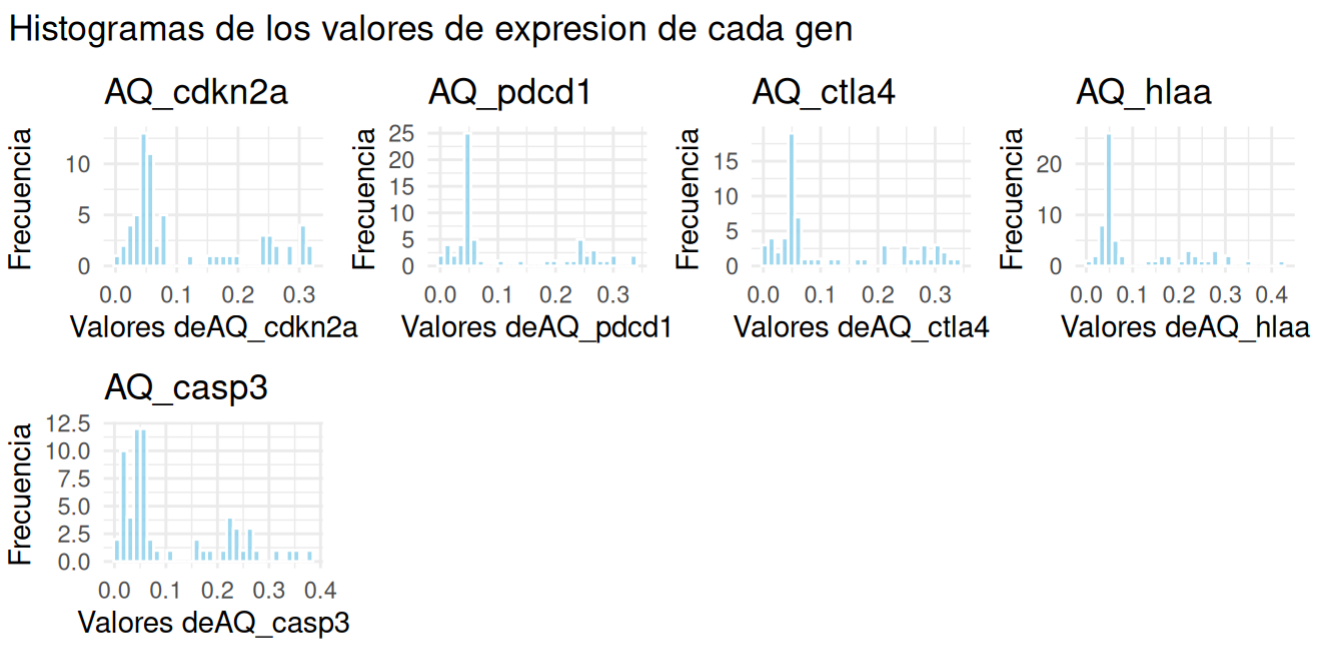

B/ Análisis visual mediante QQplots para determinar si la expresión génica sigue una distribución normal.

```
qqplots <- list()

for (i in AQ_names) {
  p <- ggplot(df_AQ, aes(sample = .data[[i]])) +
    stat_qq() +
    stat_qq_line(color = "red") +
    ggtitle(paste("QQ plot -", i))

  qqplots[[paste0("qq_", i)]] <- p
}
```

```
# Gráfico combinado de los qqplots variables de 1-12
combined_qqplots_1 <- (qqplots[[1]] + qqplots[[2]] + qqplots[[3]] + qqplots[[4]
  plot_layout(ncol = 4, nrow = 4) +
  plot_annotation(
    title = "QQ plots de los valores de expresion de cada gen",
    theme = theme_minimal()
  )

# Gráfico combinado de los qqplots variables de 13-25
combined_qqplots_2 <- (qqplots[[13]] + qqplots[[14]] + qqplots[[15]] + qqplots[
```

```
  plot_layout(ncol = 4, nrow = 4) +
  plot_annotation(
    title = "qqplots de los valores de expresion de cada gen",
    theme = theme_minimal()
  )

# Gráfico combinado de los qqplots variables de 26-30
combined_qqplots_3 <- (qqplots[[26]] + qqplots[[27]] + qqplots[[28]] + qqplots[
  plot_layout(ncol = 4, nrow = 4) +
  plot_annotation(
    title = "qqplots de los valores de expresion de cada gen",
    theme = theme_minimal()
  )
combined_qqplots_1;combined_qqplots_2;combined_qqplots_3
```

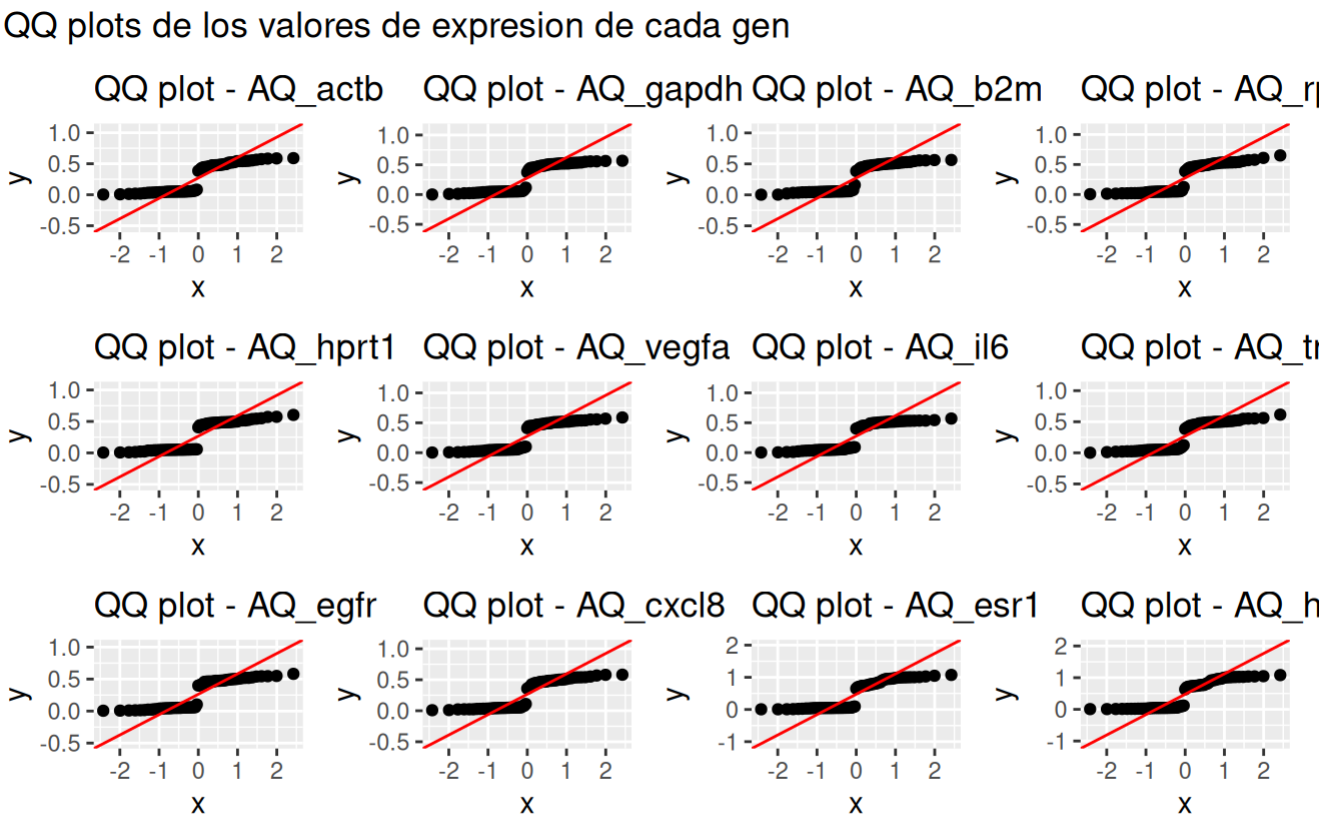

qqplots de los valores de expresion de cada gen

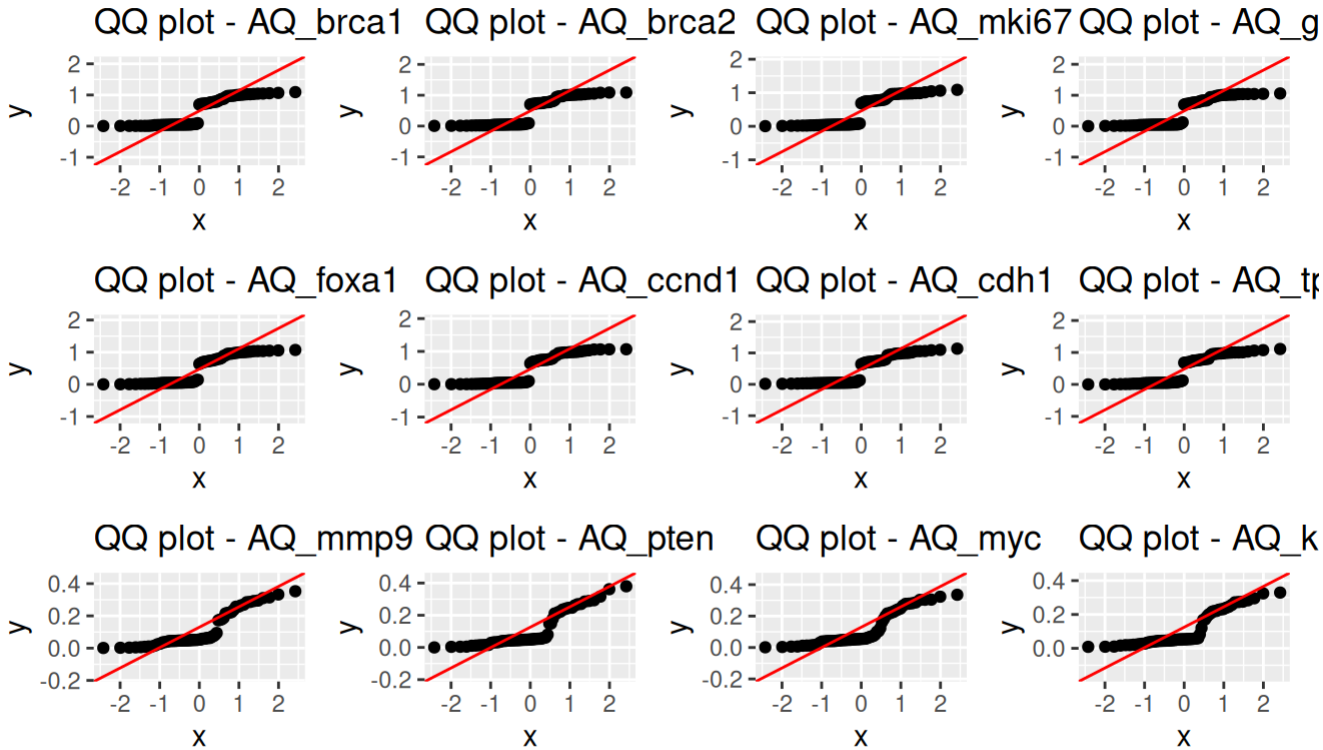

qqplots de los valores de expresion de cada gen

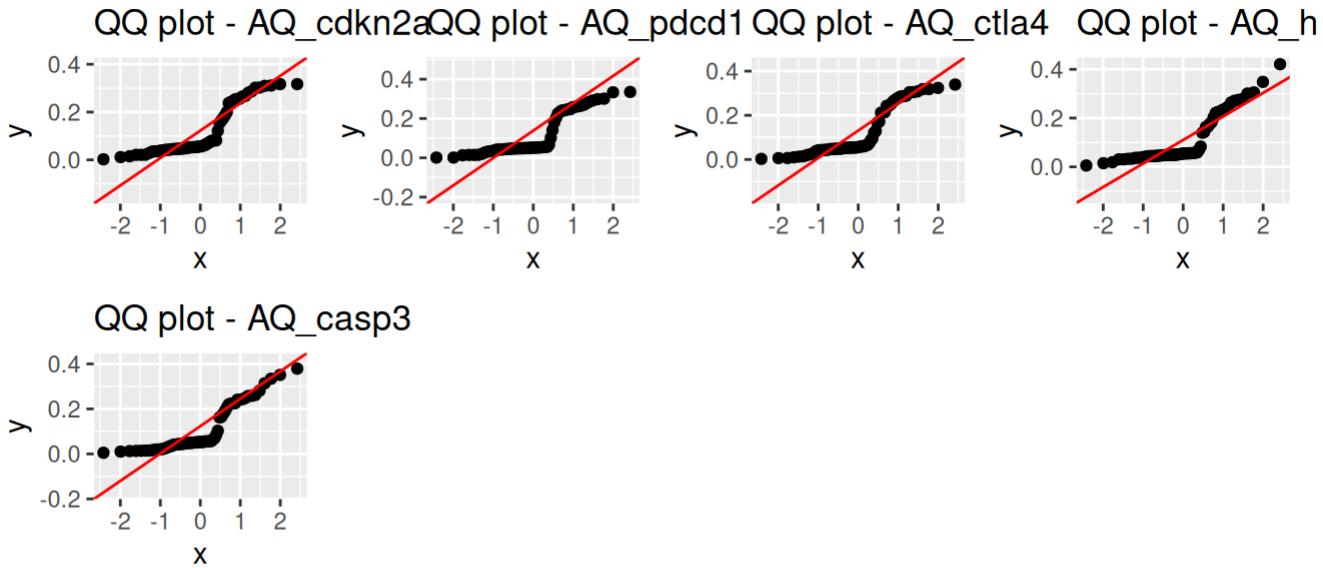

C/Contraste de hipótesis para reconfirmar normalidad de la expresión de los genes.

```r
tabla_modelo1 <- data.frame(
  Variable = AQ_names,
  Test_utilizado = character(length(AQ_names)),
  Valor_p = numeric(length(AQ_names)),
  Interpretación = character(length(AQ_names)),
  stringsAsFactors = FALSE
)

for (i in seq_along(AQ_names)) {
  gen <- AQ_names[i]
  x <- df_AQ[[gen]]
  x <- x[!is.na(x)] # Eliminamos los posibles NA puesto que los test de normali

  # Elegir test según N
  if (length(x) > 50) {
    p <- ad.test(x)$p.value
    test_name <- "Anderson-Darling"
  } else {
    p <- shapiro.test(x)$p.value
    test_name <- "Shapiro-Wilk"
  }

  tabla_modelo1$Test_utilizado[i] <- test_name
  tabla_modelo1$Valor_p[i] <- p
  tabla_modelo1$Interpretación[i] <- ifelse(p > 0.05,
    "Compatible con normalidad",
    "No normal"
  )
}

tabla_modelo1
```

```r
# Formatear con gt

tabla_modelo1_gt <- tabla_modelo1 %>%
  gt() %>%
  tab_header(
    title = "Tabla modelo 1 - Prueba de normalidad de los genes"
  ) %>%
  fmt_number(
    columns = everything(),
    decimals = 2
  ) %>%
  tab_style(
    style = cell_text(weight = "bold"),
    locations = cells_column_labels(everything())
  )
```

```
tabla_modelo1_gt
```

Tabla modelo 1 - Prueba de normalidad de los genes

Variable	Test_utilizado	Valor_p	Interpretación
AQ_actb	Anderson-Darling	0.00	No normal
AQ_gapdh	Anderson-Darling	0.00	No normal
AQ_b2m	Anderson-Darling	0.00	No normal
AQ_rpl13a	Anderson-Darling	0.00	No normal
AQ_hprt1	Anderson-Darling	0.00	No normal
AQ_vegfa	Anderson-Darling	0.00	No normal
AQ_il6	Anderson-Darling	0.00	No normal
AQ_tnf	Anderson-Darling	0.00	No normal
AQ_egfr	Anderson-Darling	0.00	No normal
AQ_cxcl8	Anderson-Darling	0.00	No normal
AQ_esr1	Anderson-Darling	0.00	No normal
AQ_her2	Anderson-Darling	0.00	No normal
AQ_brca1	Anderson-Darling	0.00	No normal
AQ_brca2	Anderson-Darling	0.00	No normal
AQ_mki67	Anderson-Darling	0.00	No normal
AQ_gata3	Anderson-Darling	0.00	No normal
AQ_foxa1	Anderson-Darling	0.00	No normal
AQ_ccnd1	Anderson-Darling	0.00	No normal
AQ_cdh1	Anderson-Darling	0.00	No normal
AQ_tp53	Anderson-Darling	0.00	No normal
AQ_mmp9	Anderson-Darling	0.00	No normal
AQ_pten	Anderson-Darling	0.00	No normal
AQ_myc	Anderson-Darling	0.00	No normal
AQ_kras	Anderson-Darling	0.00	No normal

Tabla modelo 1 - Prueba de normalidad de los genes			
Variable	**Test_utilizado**	**Valor_p**	**Interpretación**
AQ_akt1	Anderson-Darling	0.00	No normal
AQ_cdkn2a	Anderson-Darling	0.00	No normal
AQ_pdcd1	Anderson-Darling	0.00	No normal
AQ_ctla4	Anderson-Darling	0.00	No normal
AQ_hlaa	Anderson-Darling	0.00	No normal
AQ_casp3	Anderson-Darling	0.00	No normal

Interpretación de resultados de la Tabla 1

La Tabla 1 resume los resultados de la evaluación de normalidad de la expresión de 30 genes mediante la prueba de Anderson-Darling. Todos los genes presentan un valor p de 0.00, lo que indica que se rechaza la hipótesis nula de normalidad en todos los supuestos. Esto implica que, de forma generalizada en el set de genes estudiado, las distribuciones de expresión génica no se ajustan a un patrón de normalidad, lo cual afecta a la selección de métodos estadísticos a seleccionar para análisis posteriores. Este resultado coincide con lo observado previamente en los histogramas y, más importante, en los QQplots, donde los datos no se ajustaban a la línea esperada en caso de normalidad.

En este contexto, el uso de técnicas paramétricas no sería adecuado, por lo que se sugiere considerar métodos no paramétricos para cumplir los supuestos requeridos. La falta de normalidad se observa tanto en genes de referencia, como ACTB y GAPDH, cuya expresión es generalmente constante; como en genes funcionalmente relevantes, incluyendo TP53, VEGFA y MYC, involucrados en la proliferación celular, metabolismo y cáncer.

Por tanto, los resultados destacan la necesidad de adaptar los análisis a la distribución real de los datos para garantizar conclusiones correctas en el estudio de la expresión génica.

PARTE 2A - En función del tratamiento (1er nivel) y de la extensión tumoral (2º nivel), crea una tabla descriptiva (tabla modelo 2) únicamente con las variables de genes.

```
normalidad <- sapply(AQ_names, function(g) {
  x <- datos[[g]]
  x <- x[!is.na(x)]
  if (length(x) > 50) {
    p <- ad.test(x)$p.value
  } else {
    p <- shapiro.test(x)$p.value
```

```
  }
  return(p >= 0.05) # TRUE = normal
})

stat_list <- lapply(normalidad, function(is_normal) {
  if (is_normal) {
    "{mean} ({sd})"
  } else {
    "{median} ({p25}-{p75})"
  }
})
names(stat_list) <- AQ_names

tabla_modelo2 <- datos %>%
  select(tratamiento, extension, all_of(AQ_names)) %>%
  tbl_strata(
    strata = tratamiento,
    .tbl_fun = ~ .x %>%
      tbl_summary(
        by = extension,
        statistic = stat_list,
        digits = all_continuous() ~ 1
      ) %>%
      add_p(
        test = all_continuous() ~ "wilcox.test",
        pvalue_fun = ~ style_pvalue(.x, digits = 3)
      )
  )%>%
 modify_caption("**Tabla modelo 2 - Expresión génica según extensión de enferme

tabla_modelo2
```

	farmaco			placebo		
Characteristic	localizado N = 16[1]	metastasico N = 16[1]	p-value[2]	localizado N = 16[1]	metastasico N = 17[1]	p-value[2]
AQ_actb	0.1 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_gapdh	0.0 (0.0–0.0)	0.5 (0.5–0.5)	<0.001	0.1 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_b2m	0.1 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.1 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_rpl13a	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001

[1] Median (Q1–Q3)

[2] Wilcoxon rank sum exact test

Tabla modelo 2 - Expresión génica según extensión de enfermedad, estratificado por tratamiento

Characteristic	farmaco			placebo		
	localizado N = 16[1]	metastasico N = 16[1]	p-value[2]	localizado N = 16[1]	metastasico N = 17[1]	p-value[2]
AQ_hprt1	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_vegfa	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_il6	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_tnf	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_egfr	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_cxcl8	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001	0.0 (0.0–0.1)	0.5 (0.5–0.5)	<0.001
AQ_esr1	0.0 (0.0–0.1)	0.0 (0.0–0.1)	0.985	0.8 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_her2	0.0 (0.0–0.0)	0.0 (0.0–0.1)	0.515	0.7 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_brca1	0.0 (0.0–0.1)	0.0 (0.0–0.0)	0.897	0.8 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_brca2	0.0 (0.0–0.1)	0.1 (0.0–0.1)	0.073	0.7 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_mki67	0.0 (0.0–0.1)	0.0 (0.0–0.1)	0.809	0.8 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_gata3	0.1 (0.0–0.1)	0.0 (0.0–0.1)	0.039	0.8 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_foxa1	0.0 (0.0–0.0)	0.1 (0.0–0.1)	0.032	0.7 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_ccnd1	0.0 (0.0–0.1)	0.0 (0.0–0.0)	0.539	0.7 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_cdh1	0.0 (0.0–0.1)	0.0 (0.0–0.1)	0.539	0.7 (0.7–0.8)	1.0 (1.0–1.1)	<0.001
AQ_tp53	0.0 (0.0–0.1)	0.0 (0.0–0.1)	0.468	0.7 (0.7–0.8)	1.0 (1.0–1.0)	<0.001
AQ_mmp9	0.1 (0.0–0.2)	0.0 (0.0–0.1)	0.305	0.1 (0.0–0.3)	0.1 (0.0–0.2)	0.631
AQ_pten	0.1 (0.0–0.2)	0.0 (0.0–0.1)	0.985	0.1 (0.0–0.2)	0.0 (0.0–0.1)	0.110
AQ_myc	0.1 (0.0–0.1)	0.0 (0.0–0.1)	0.809	0.1 (0.1–0.2)	0.1 (0.0–0.2)	0.345
AQ_kras	0.1 (0.0–0.2)	0.1 (0.0–0.2)	0.564	0.1 (0.0–0.3)	0.1 (0.0–0.2)	0.309
AQ_akt1	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.867	0.1 (0.0–0.3)	0.1 (0.0–0.1)	0.245
AQ_cdkn2a	0.1 (0.0–0.2)	0.1 (0.0–0.2)	0.381	0.1 (0.0–0.3)	0.1 (0.0–0.2)	0.179
AQ_pdcd1	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.696	0.1 (0.0–0.2)	0.1 (0.0–0.2)	0.873
AQ_ctla4	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.752	0.1 (0.0–0.3)	0.1 (0.0–0.2)	0.382

[1] Median (Q1–Q3)

[2] Wilcoxon rank sum exact test

Characteristic	farmaco			placebo		
	localizado N = 16[1]	metastasico N = 16[1]	p-value[2]	localizado N = 16[1]	metastasico N = 17[1]	p-value[2]
AQ_hlaa	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.616	0.1 (0.0–0.2)	0.0 (0.0–0.2)	0.168
AQ_casp3	0.0 (0.0–0.2)	0.1 (0.0–0.2)	0.287	0.1 (0.0–0.2)	0.1 (0.0–0.2)	0.345

[1] Median (Q1–Q3)

[2] Wilcoxon rank sum exact test

Interpretación de los resultados de la Tabla 2

En la tabla 2 vemos la comparación de la expresión génica entre tumores localizados y metastásicos, estratificada por tratamiento (grupo fármaco versus grupo placebo). Para ellos se emplea el método estadístico del test de Wilcoxon, para la comparación de medianas de dos grupos independientes de datos no paramétricos.

En el grupo tratado con el fármaco, se observan diferencias estadísticamente significativas entre los tumores localizados y los metastásicos para varios genes, como GATA3 y FOXA1 relacionados con proliferación y diferenciación tumoral. Esto puede sugierir cambios en los patrones de expresión génica asociados al estado metastásico. En cambio, genes clave implicados en oncogénesis como TP53, BRCA1/2 o MYC no muestran diferencias significativas en este grupo. En el grupo placebo, la mayoría de los genes presentan diferencias significativas entre los estados tumorales, siendo la expresión más elevada en los casos de tumores metastásicos. Esto indica una asociación entre la progresión tumoral y la sobreexpresión génica en ausencia de tratamiento.

Por tanto, los resultados sugieren un posible efecto del fármaco en la disminución de la magnitud de la sobreexpresión génica en tumores metastásicos.

PARTE 2B - En función de la edad en 2 categorías según la mediana (categoría 1: edad <percentil 50 de edad; categoría 2: edad >=percentil 50 de edad), crea una tabla descriptiva (tabla modelo 3) únicamente con las variables de genes.

```
p50_edad <- quantile(datos$edad, probs = 0.50, na.rm = TRUE)

datos <- datos %>%
  mutate(
    edad_cat = cut(
      edad,
      breaks = c(-Inf, p50_edad, Inf),
      labels = c("Edad_cat < percentil 50", "Edad_cat ≥ percentil 50"),
      right = FALSE
```

```
    )
  )

tabla_modelo3 <- datos %>%
  select(edad_cat, all_of(AQ_names)) %>%
  tbl_summary(
    by = edad_cat,
    statistic = stat_list,
    digits = all_continuous() ~ 1
  ) %>%
  add_p(
    test = all_continuous() ~ "wilcox.test",
    pvalue_fun = ~ style_pvalue(.x, digits = 3)
  ) %>%

  modify_caption("**Tabla modelo 3 - Comparación de expresión génica según edad

tabla_modelo3
```

Characteristic	Edad_cat < percentil 50 N = 32[1]	Edad_cat ≥ percentil 50 N = 33[1]	p-value[2]
AQ_actb	0.4 (0.1–0.5)	0.1 (0.0–0.5)	0.193
AQ_gapdh	0.4 (0.1–0.5)	0.1 (0.0–0.5)	0.681
AQ_b2m	0.4 (0.0–0.5)	0.1 (0.1–0.5)	0.749
AQ_rpl13a	0.4 (0.0–0.5)	0.1 (0.0–0.5)	0.789
AQ_hprt1	0.4 (0.0–0.5)	0.1 (0.1–0.5)	0.901
AQ_vegfa	0.5 (0.1–0.5)	0.1 (0.0–0.5)	0.084
AQ_il6	0.4 (0.0–0.5)	0.1 (0.0–0.5)	0.318
AQ_tnf	0.4 (0.1–0.5)	0.1 (0.0–0.5)	0.087
AQ_egfr	0.4 (0.0–0.5)	0.1 (0.0–0.5)	0.407
AQ_cxcl8	0.4 (0.0–0.5)	0.1 (0.0–0.5)	0.672
AQ_esr1	0.7 (0.1–1.0)	0.1 (0.0–0.8)	0.152
AQ_her2	0.7 (0.0–1.0)	0.1 (0.0–0.8)	0.415
AQ_brca1	0.7 (0.0–1.0)	0.1 (0.0–0.8)	0.189

[1] Median (Q1–Q3)

[2] Wilcoxon rank sum exact test

Tabla modelo 3 - Comparación de expresión génica según edad

Characteristic	Edad_cat < percentil 50 N = 32[1]	Edad_cat ≥ percentil 50 N = 33[1]	p-value[2]
AQ_brca2	0.7 (0.0–1.0)	0.1 (0.0–0.8)	0.253
AQ_mki67	0.7 (0.0–1.0)	0.1 (0.0–0.8)	0.493
AQ_gata3	0.8 (0.1–1.0)	0.1 (0.0–0.8)	0.097
AQ_foxa1	0.7 (0.0–1.0)	0.1 (0.0–0.8)	0.779
AQ_ccnd1	0.7 (0.0–1.0)	0.1 (0.0–0.7)	0.502
AQ_cdh1	0.7 (0.0–1.0)	0.1 (0.0–0.8)	0.247
AQ_tp53	0.7 (0.0–1.0)	0.1 (0.1–0.8)	0.422
AQ_mmp9	0.1 (0.0–0.2)	0.0 (0.0–0.1)	0.222
AQ_pten	0.1 (0.0–0.2)	0.0 (0.0–0.1)	0.019
AQ_myc	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.059
AQ_kras	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.212
AQ_akt1	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.415
AQ_cdkn2a	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.137
AQ_pdcd1	0.1 (0.0–0.2)	0.1 (0.0–0.1)	0.461
AQ_ctla4	0.1 (0.1–0.2)	0.1 (0.0–0.1)	0.171
AQ_hlaa	0.1 (0.0–0.2)	0.0 (0.0–0.1)	0.094
AQ_casp3	0.1 (0.1–0.2)	0.0 (0.0–0.1)	0.001

[1] Median (Q1–Q3)

[2] Wilcoxon rank sum exact test

Interpretación de los resultados de la Tabla 3

La tabla 3 compara la expresión génica entre los dos grupos de edad. Para el análisis, se utiliza en el método estadístico del test de Wilcoxon, para la comparación de medianas de dos grupos independientes de datos no paramétricos.

La mayoría de genes evaluados (como actb, gapdh o b2m) son genes relacionados con proliferación y regulación celular que no presentan diferencias significativas entre grupos ($p>0.05$). Sin embargo, destacan dos únicos genes con significación estadística, PTEN y CASP3. Estos dos genes presentan menor expresión en el grupo ≥P50.

PTEN es un supresor tumoral clave y CASP3 participa en el proceso de apoptosis celular. Por

tanto, su menor expresión en el grupo ≥P50 podría indicar mayor potencial proliferativo así como la resistencia a la muerte celular. Esto tiene sentido biológico puesto que el cáncer es más agresivo en pacientes de mayor edad, situados en el grupo ≥P50.