Análisis de datos metagenómicos con QIIME2

Melissa Ndombasi Bokuy

Parte 1. Selección de profundidad

En primer lugar, se revisan cuántas secuencias tiene cada muestra, valorando los descriptivos básicos de la tabla inferior.

Estadístico de la frecuencia por muestra	Valor
Mínimo	2
Máximo	2127
Media	1190
Mediana	1160

Considerando estos valores, y evaluando visualmente el impacto de la profundidad en la pérdida de datos en la plataforma view QIIME2 (imagen 1 del anexo), se escoge como profundidad 900, a fin de conservar la mayor cantidad posible de muestras (un 70%) sin usar una profundidad demasiado baja, para evitar incluir valores extremos que afecten al análisis.

Parte 2. Determinación de variables categóricas más fuertemente asociadas con las diferencias en riqueza e igualdad de la comunidad.

Evaluando la biodiversidad (cantidad de especies) y la igualdad de forma independiente, con el índice de biodiversidad observada y el índice de Evenness respectivamente, observamos que la variable más fuertemente asociada a la biodiversidad observada es la vegetación, mientras que la que más se relaciona con la igualdad es el transect-name.

	Índice de biodiversidad observada (Biodiversidad)	Índice de Evenness (Uniformidad)	Índice de Shannon (Biodiversidad y uniformidad)
Vegetation	H=9.757 P-value=0.002	H=3.700 P-value=0.054	H=7.85 P-value= 0.005
Site-name	H= 24.938 P-value=0.051	H=25.837 P-value=0.040	H=24.5 P-value= 0.057
Transect-name	H=1.797 P-value=0.180	H=9.391 P-value=0.002	H=5.25 P-value= 0.021
Extract-group-no	H=11.130 P-value=0.133	H=15.553 P-value=0.030	H=13.13 P-value= 0.069

No obstante, utilizando el índice de Shannon para evaluar conjuntamente riqueza de especies y su uniformidad, vemos que la variable categórica que más está asociada a la riqueza de especies e igualdad de ésta es la vegetación (p-value= 0.005, H=7.85; imagen 2). Generalmente, un valor H superior a 3 ya indica alta biodiversidad, por lo que se puede afirmar que esta muestra presenta un valor muy alto tanto de biodiversidad en variedad de especies, como en uniformidad entre las mismas.

Parte 3. Comparación de secuencias con BLAST vs QIIME2

Seleccionamos dos organismos para hacer la comparación. En ambos casos utilizaremos blastn para buscar la secuencia de nucleótidos en la base de datos “rRNA/ITS” dejando el resto de los parámetros preseleccionados (16S ribosomal, optimize for megablast).

CASO 1:

- Organismo en QIIME2: k__Bacteria; p__Proteobacteria; c__Alphaproteobacteria; o__Rhizobiales; f__Hyphomicrobiaceae; g__*Hyphomicrobium*; s__
- Organismo en BLASTN: *Methylothermalis aethiopiae* (con un 100% de identidad y cobertura).

Interpretación: en BLASTN el primer resultado con mayor identidad no coincidía con el género de QIIME2, pero era una especie de la misma familia Hyphomicrobiaceae. No obstante, los siguientes organismos con alto porcentaje de identidad eran del mismo género *Hyphomicrobium (imagen 3),* indicando que se trata de especies muy similares. Las diferencias pueden deberse a que ambas herramientas utilizan diferentes bases de datos donde el nivel de anotación del genoma de las especies comentadas puede estar distintamente desarrollado.

CASO 2:

- Organismo en QIIME2: k__Bacteria; p__Proteobacteria; c__Alphaproteobacteria; o__Sphingomonadales; f__Sphingomonadaceae; g__*Kaistobacter*; s__
- Organismo en BLASTN: *Sphingomonas crocodyli* (con un 99% de identidad y 100% de cobertura).

Interpretación: al igual que en el caso anterior, en BLASTN el primer resultado con mayor identidad coincide en la familia (Sphingomonadaceae) pero no en el género del organismo seleccionado en QIIME (imagen 4). BLASTN compara secuencias contra una base de datos más amplia de genomas (rRNA/ITS) presentando una mayor resolución taxonómica. Mientras que QIIME 2

(Greengenes) usa una base de datos estandarizada de regiones del 16S (V4–V5) optimizada para análisis masivos, presentando así menor nivel de detalle a nivel especie, pudiéndose generar discrepancias en la clasificación taxonómica entre ambas herramientas a nivel especie como hemos observado.

Parte 4. Identificación de generos con diferencias significativas en abundancia entre grupos de muestras.

El análisis ANCOM nos permite estudiar la abundancia deferencial entre los organismos de la muestra seleccionada. En la imagen 5 vemos como sobre la totalidad de taxones presentes, sólo unos pocos se diferencian significativamente del resto en función de la vegetación. Los taxones destacados se detallan en la tabla de la imagen 6 siendo estos de los filos Verrucomicrobia, Gemmatimonadetes y Acidobacteria. Las diferencias detectadas entre estos grupos en función de la vegetación tienen un gran sentido biológico puesto que se trata de taxones extremófilos condicionados a ambientes muy específicos: Verrucomicrobia, se asocia a suelos ricos en carbono vegetal y materia orgánica; Gemmatimonadetes se relaciona con suelos secos con baja disponibilidad hídrica; y Acidobacteria se caracteriza por estar en sustratos pobres en nutrientes.

De este modo, la presencia de estos taxones actúa como biomarcador del tipo de suelo y su ambiente.

Parte 5. Análisis permanova de biodiversidad beta

El análisis de beta diversidad PERMANOVA evalúa si la composición de las comunidades microbianas difiere significativamente entre grupos de muestras según una variable de los metadatos, en este caso, la variable vegetación.

Los boxplot obtenidos indican la distribución de las distancias dentro de cada grupo. Como se muestra en la figura 7, hay una diferencia significativa entre la composición de especies entre los dos grupos categóricos de la vegetación, grupos "no" y "yes" (pseudo-F = 2.028, p = 0.001).

ANEXO

Imagen 1. Archivo table.qvz donde se visualiza el impacto de la selección de una profundidad de 900.

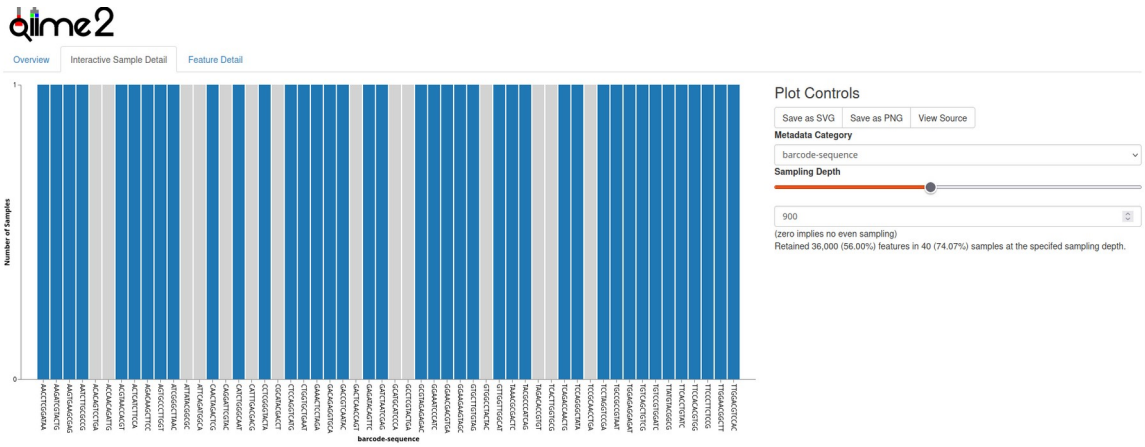
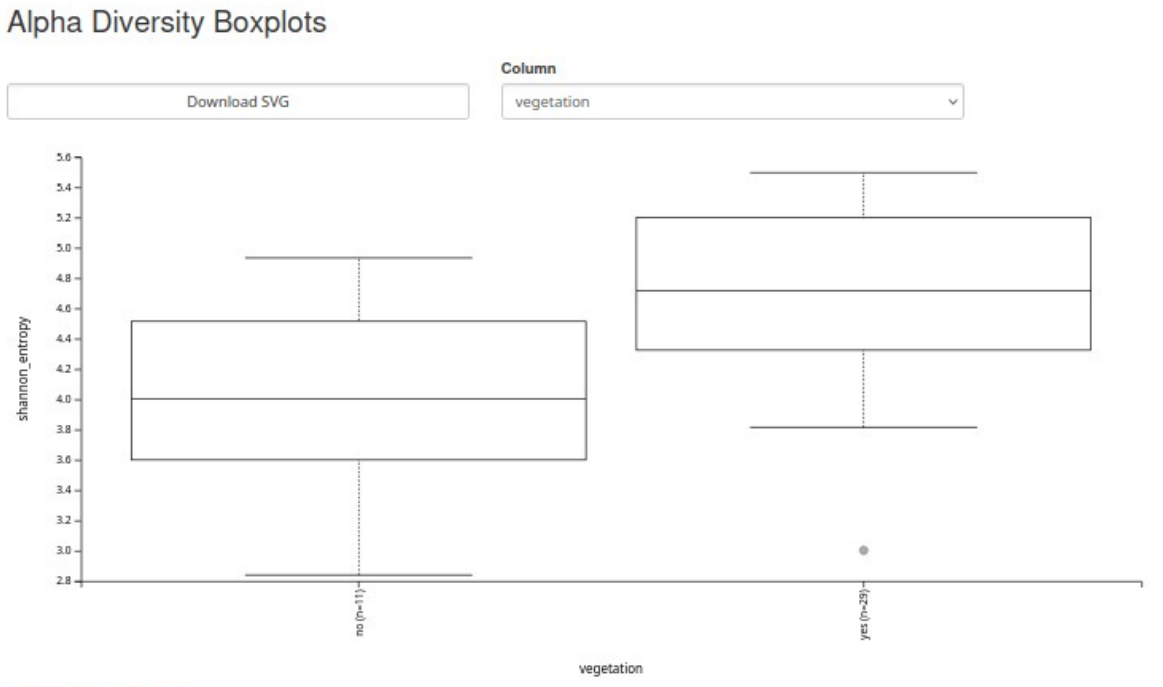


Imagen 2: resultado del índice de Shannon en función de la vegetación.



Kruskal-Wallis (all groups)

	Result
H	7.850370823457439
p-value	0.005081028429411704

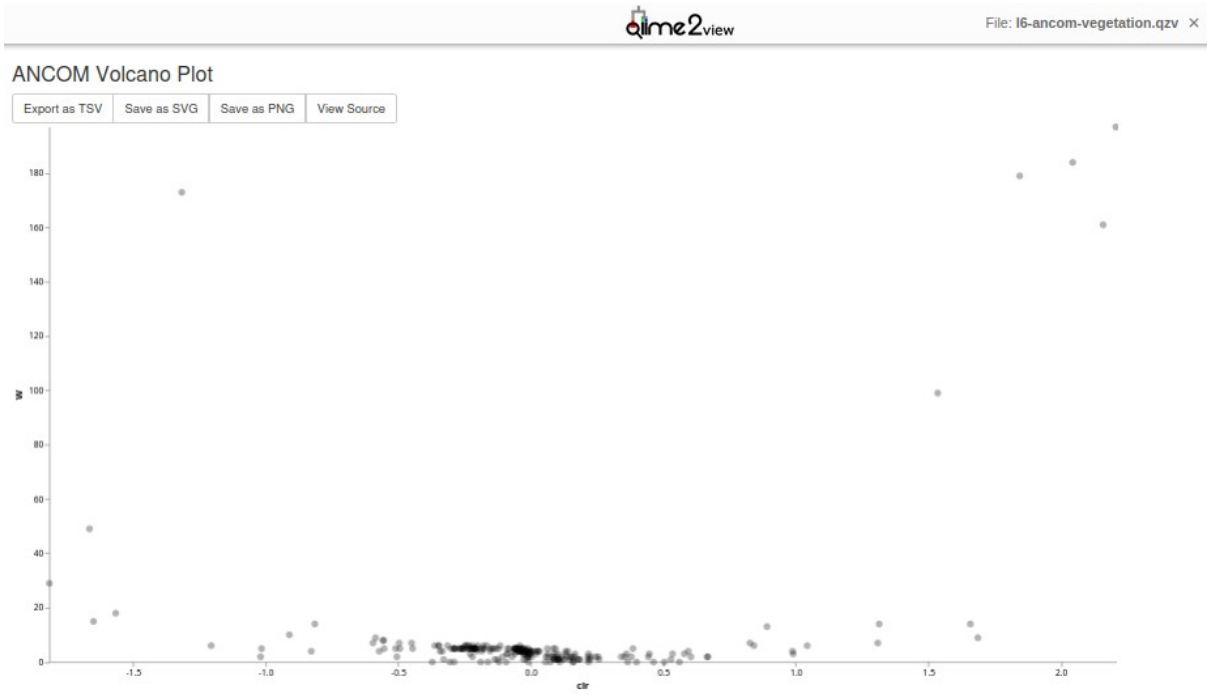
Imagen 3: resultado de la búsqueda del caso 1 en BLASTN.

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
Methylothermalis aethiopiae strain LS7-MT 16S ribosomal RNA, partial sequence	Methylothermalis aethiopiae	420	420	100%	2e-117	100.00%	1374	NR_178804.1
Hyphomicrobium aestuarii strain ATCC 27483 16S ribosomal RNA, partial sequence	Hyphomicrobium aestuarii	409	409	100%	5e-114	99.12%	1387	NR_104954.1
Hyphomicrobium vulgare strain JCM 6889 16S ribosomal RNA, partial sequence	Hyphomicrobium vulgare	409	409	100%	5e-114	99.12%	1406	NR_104697.1

Imagen 4: resultado de la búsqueda del caso 2 en BLASTN.

Description	Scientific Name	Max Score	Total Score	Query Cover	E value	Per. Ident	Acc. Len	Accession
Sphingomonas crocodyli strain CCP-7 16S ribosomal RNA, partial sequence	Sphingomonas crocodyli	409	409	100%	5e-114	99.12%	1452	NR_171471.1
Rhizorhabdus phycosphaerae strain MK52 16S ribosomal RNA, partial sequence	Rhizorhabdus phycosphaerae	403	403	100%	2e-112	98.68%	1339	NR_181194.1
Rhizorhabdus phycosphaerae strain MK52 16S ribosomal RNA, partial sequence	Rhizorhabdus phycosphaerae	403	403	100%	2e-112	98.68%	1038	NR_180356.1

Imagen 5: gráfico ANCOM de la abundancia diferencial de la muestra.



ANCOM statistical results

	W
k__Bacteria;p__Verrucomicrobia;c__[Spartobacteria];o__[Chthoniobacterales];f__[Chthoniobacteraceae];g__DA101	197
k__Bacteria;p__Gemmatimonadetes;c__Gemm-1;o__;f__;g__	184
k__Bacteria;p__Acidobacteria;c__[Chloracidobacteria];o__RB41;f__;g__	179
k__Bacteria;p__Gemmatimonadetes;c__Gemm-3;o__;f__;g__	173

Imagen 6: tabla de resultados del análisis ANCOM.

Percentile abundances of features by group

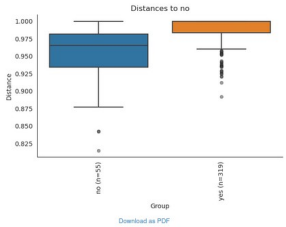
Percentile	0.0	25.0	50.0	75.0	100.0	0.0	25.0	50.0	75.0	100.0
Group	no	no	no	no	no	yes	yes	yes	yes	yes
k__Bacteria;p__Verrucomicrobia;c__[Spartobacteria];o__[Chthoniobacterales];f__[Chthoniobacteraceae];g__DA101	1.0	1.0	1.0	1.0	1.0	1.0	1.0	13.0	73.5	252.0
k__Bacteria;p__Gemmatimonadetes;c__Gemm-1;o__;f__;g__	1.0	1.0	1.0	5.0	53.0	1.0	6.5	47.0	80.0	114.0
k__Bacteria;p__Acidobacteria;c__[Chloracidobacteria];o__RB41;f__;g__	1.0	1.0	1.0	1.0	16.0	1.0	1.0	24.0	37.0	108.0
k__Bacteria;p__Gemmatimonadetes;c__Gemm-3;o__;f__;g__	1.0	1.0	1.0	15.5	60.0	1.0	1.0	1.0	1.0	12.0

Imagen 7: resultado del análisis de beta biodiversidad PERMANOVA.

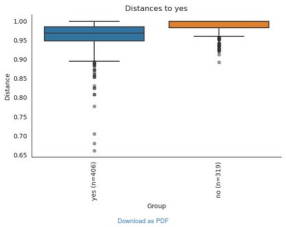
PERMANOVA results	
method name	PERMANOVA
test statistic name	pseudo-F
sample size	40
number of groups	2
test statistic	2.028382
p-value	0.001
number of permutations	999

Group significance plots

Download raw data as TSV



Download as PDF



Download as PDF

Pairwise permanova results

Download CSV

Group 1	Group 2	Sample size	Permutations	pseudo-F	p-value	q-value
no	yes	40	999	2.028382	0.001	0.001